

Regresión espacial

Gustavo A. García

ggarci24@eafit.edu.co

Econometría Espacial

PhD/Maestría en Economía

Universidad EAFIT

Link slides en formato **html**

Link slides en formato **PDF**

En este tema

- Motivación
- Taxonomía de los modelos lineales con dependencia espacial
- Ineficiencia de los estimadores MCO
- Métodos de estimación
- Comparación de modelos
- Efectos directos e indirectos (o *spatial spillover effects*)
- Ejercicio aplicado en R: corte transversal
- Ejercicio aplicado en R: datos panel

Lecturas

- Elhorst, J.P. (2010). "Applied Spatial Econometrics: Raising the Bar". *Spatial Economic Analysis*, 5(1):9–28
- Millo, G. y Piras, G. (2012). "splm: Spatial Panel Data Models in R". *Journal of Statistical Software*, 47(1):1–37
- Elhorst, J.P. (2014). *Spatial Econometrics from Cross-Sectional Data to Spatial Panels*, Springer
- LeSage, J. y Pace, R. (2014). "Interpreting spatial econometrics models". En Fischer, M. y Nijkamp, P. (Eds.), *Handbook of Regional Science*, Springer
- Halleck Vega, S. y Elhorst, J.P. (2015). "The SLX model", *Journal of Regional Science*, 55(3):339–363
- Golgher, A. y Voss, P. (2016). "How to interpret the coefficients of spatial models: spillovers, direct and indirect Effects". *Spatial Demography*, 4:175–205
- Belotti, F., Hughes, G. y Mortari, A. (2017). "Spatial panel-data models using Stata", *The Stata*

Motivación

PGD no espacial

En el caso lineal: $y_i = \text{tbf{x}}_i \boldsymbol{\beta} + u_i$ $u_i \sim N(0, \sigma^2)$, $i=1, \dots, n$ Supuestos:

- Los valores observados en la localización i son independientes de aquellos en la localización j
- Los residuales son independientes $(\Longrightarrow E[u_i u_j] = E[u_i] E[u_j] = 0)$

El supuesto de independencia simplifica enormemente el modelo, pero puede ser difícil de justificar en algunos contextos

Motivación

PGD no espacial

Con dos vecinos i y j :

$$y_i = \alpha_j y_j + \text{bf}{x}_i \beta + u_i$$

$$y_j = \alpha_i y_i + \text{bf}{x}_j \beta + u_j \quad u_i \sim N(0, \sigma^2), i=1$$

$$u_j \sim N(0, \sigma^2), j=2 \quad \text{Supuestos:}$$

- Los valores observados en la localización i dependen de aquellos en la localización j y viceversa
- El PGD es "simultáneo"

Motivación

PGD espacial




Con (n) observaciones, se puede generalizar:

$$y_i = \rho \sum_{j=1}^n w_{ij} y_j + \mathbf{x}_i^T \boldsymbol{\beta} + u_i$$
$$u_i \sim N(0, \sigma^2), \quad i=1, \dots, n$$
 En notación matricial:
$$\mathbf{Y} = \rho \mathbf{W} \mathbf{Y} + \mathbf{X} \boldsymbol{\beta} + \mathbf{u}$$
$$\mathbf{u} \sim N(0, \sigma^2 \mathbf{I}_n), \quad i=1, \dots, n$$
 donde $(\mathbf{W})$ es la matriz de pesos espaciales, (ρ) es un parámetro escalar de autocorrelación espacial e $(\mathbf{I}_n)$ es una matriz identidad $(n \times n)$

Motivación

PGD espacial

- Cuando $\rho=0$, la variable no es espacialmente autocorrelacionada. La información sobre una medida en una localización no nos da información de los valores de las localizaciones vecinas $\rightarrow$ independencia espacial
- Cuando $\rho>0$, la variable es positivamente autocorrelacionada espacialmente. Valores vecinos tienden a ser similares unos a otros $\rightarrow$ clustering
- Cuando $\rho<0$, la variable es negativamente autocorrelacionada espacialmente. Valores vecinos tienden a ser diferentes unos a otros $\rightarrow$ segregación



Taxonomía de los modelos lineales con dependencia espacial

Manski (1993) resalta que existen tres diferentes tipos de efectos interactivos que pueden explicar por qué una observación asociada con una localización específica puede depender de otra localización:

1. **Efectos de interacción endógenos**: donde el comportamiento de una unidad espacial (o sus tomadores de decisiones) en una localización depende de la decisión tomada por otras unidades espaciales
2. **Efectos de interacción exógenos**: donde el comportamiento de una unidad espacial en una localización depende variables explicativas independientes, de otra unidad espacial
3. **Efectos correlacionados**: donde similares características no observadas dan como resultado un comportamiento similar

Taxonomía de los modelos lineales con dependencia espacial

El modelo de Manski (1993) o modelo más general (*General Nesting spatial model - GNSM*) en tiene la forma:

$$Y = \rho WY + \alpha \iota_N + X\beta + W\theta + u$$

$$u = \lambda Wu + \epsilon$$

donde ϵ (Wu): efectos de interacción endógenos entre las variables dependientes

$\textbf{W}\textbf{X}$): efectos de interacción exógenos entre las variables independientes

$\textbf{Wu}$): efectos de interacción entre los términos de error de las diferentes unidades espaciales

ρ : coeficiente espacial autorregresivo

λ : coeficiente espacial de autocorrelación

θ y β : vectores $(K \times 1)$ de parámetros fijos y desconocidos


El modelo **espacio-tiempo** se extiende con efectos específicos espaciales y de tiempo, y tiene la forma:

$$Y_t = \rho W_t Y_t + \alpha \boldsymbol{1}_N + X_t \boldsymbol{\beta} + W_t X_t \boldsymbol{\theta} + \boldsymbol{\mu} + \boldsymbol{\xi}_t \boldsymbol{1}_N + u_t$$

$$u_t = \lambda W_t u_t + \boldsymbol{\epsilon}_t$$
 donde $(\boldsymbol{\mu} = (\mu_1, \dots, \mu_N)')$. Los efectos específicos de espacio y tiempo pueden ser tratados como efectos fijos o efectos aleatorios


Taxonomía de los modelos lineales con dependencia espacial

El siguiente diagrama resume una familia de 8 modelos econométricos lineales espaciales en sección cruzada:



Taxonomía de los modelos lineales con dependencia espacial

El siguiente diagrama resume una familia de 8 modelos econométricos lineales espaciales en **datos panel** (con efectos fijos o aleatorios, y con o sin efectos específicos de tiempo):



Ineficiencia de los estimadores MCO

- En un contexto de series de tiempo, los estimadores MCO siguen siendo consistentes incluso cuando la variable dependiente rezagada esta presente en el modelo, siempre que el términos de error no muestre correlación serial
- Mientras el estimador puede ser sesgado en muestras pequeñas, éste puede aún ser usado para inferencia asintótica
- En un contexto espacial, estas reglas no se mantienen, independientemente de las propiedades del término de error
- Consideremos el modelo SAR de primer orden en corte transversal (covariables omitidas):

$$Y = \rho WY + \epsilon$$

- El estimador MCO para ρ es:

$$\widehat{\rho} = \frac{(WY)'(WY)}{(WY)'(WY)} \rho + \frac{(WY)' \epsilon}{(WY)'(WY)}$$

- Similar a series de tiempo, la esperanza del segundo término no es igual a cero

Ineficiencia de los estimadores MCO

- Asintóticamente, el estimador MCO será consistente si se cumplen dos condiciones:

$$\lim_{N \rightarrow \infty} \frac{1}{N} \text{tr}(\mathbf{W}'\mathbf{W}) = \text{tr}(\mathbf{Q}) < \infty$$
una matriz finita no singular

$$\lim_{N \rightarrow \infty} \frac{1}{N} \mathbf{W}'\mathbf{W} = \mathbf{0}$$
- Si bien la primera condición se puede satisfacer con restricciones adecuadas sobre ρ y la estructura de $\mathbf{W}$, la segunda no se mantiene en el caso especial:

$$\lim_{N \rightarrow \infty} \frac{1}{N} \mathbf{W}'\mathbf{W} = \lim_{N \rightarrow \infty} \frac{1}{N} \mathbf{W}'(\mathbf{I}_N - \rho \mathbf{W})\mathbf{W} = \lim_{N \rightarrow \infty} \frac{1}{N} \mathbf{W}'\mathbf{W} - \rho \lim_{N \rightarrow \infty} \frac{1}{N} \mathbf{W}'\mathbf{W} \neq \mathbf{0}$$

- La presencia de $\mathbf{W}$ en la expresión resulta en una forma cuadrática en el término de error
- A menos que $\rho=0$, el $\lim_{N \rightarrow \infty} \frac{1}{N} \mathbf{W}'\mathbf{W}$ no convergerá a cero

Métodos de estimación

Tres métodos han sido desarrollados en la literatura para estimar modelos que incluyen efectos de interacción espacial:

- ML: Máxima verosimilitud
- IV/GMM: variables instrumentales o método de los momentos generalizados
- MCMC: *Bayesian Markov Chain Monte Carlo approach*

Comparación de modelos

- El esquema de los 7 modelos espaciales parece sugerir que la mejor estrategia para probar por efectos de interacción espacial es iniciar por el modelo general: $(GNSM)$
- Sin embargo, como Manski (1993) plantea, al menos uno de los $(K+2)$ efectos de interacción debe ser excluido, ya que de otra forma los parámetros no podrán ser identificados $(\rightarrow)$ De acuerdo a Manski (1993) no existen limitaciones técnicas para estimar el modelo, pero los parámetros estimados no podrán interpretarse de manera adecuada, ya que los efectos endógenos y exógenos no pueden distinguirse entre sí
- Se esta divido entonces en aplicar dos enfoques: general-a-específico o específico-a-general
- LeSage y Pace (2009) argumentan que el modelo Durbin espacial es el mejor punto de partida
- Florax et al. (2003) han encontrado que una expansión de una ecuación de regresión lineal con variables espacialmente rezagadas, condicional a los resultados sobre pruebas de especificación incorrectas, supera el enfoque general-a-específico para encontrar el verdadero proceso generador de datos

Comparación de modelos

Partiendo del siguiente modelo de regresión lineal: $\textbf{Y} = \textbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ $\boldsymbol{\epsilon} \sim N(\textbf{0}, \sigma^2 \textbf{I})$ La hipótesis de no autocorrelación espacial puede ser contrastada a partir de los siguientes estadísticos:


- La I de Moran
- Tests estadísticos basados en el principio de multiplicadores de Lagrange (LM):
 - LM-Lag
 - Robust LM-Lag
 - LM-Error
 - Robust LM-Error
 - LM-SARMA
- En los tests LM los dos primeros se refieren al *spatial lag model* como alternativa, los siguientes dos se refieren al *spatial error model* como alternativa y el último se refiere a un modelo con *spatial lag* y *spatial error*

Comparación de modelos

- Todos los tests comparten una misma hipótesis nula: la ausencia de dependencia espacial
- Sin embargo, el test de la I de Moran no tiene una hipótesis alternativa claramente definida. Con lo cual no sirve para discriminar entre la existencia de un esquema de autocorrelación espacial residual o en la variable dependiente
- Por otra parte, tanto la I de Moran como los contrastes basados en el principio de LM requieren de la normalidad del término de perturbación así como la linealidad del modelo de regresión
- Los tests robustos (Robust LM-Lag y Robust LM-Error) prueban la dependencia espacial robusto a la presencia del otro. Es decir, que el Robust LM-Error prueba por dependencia en el error en la posible presencia errónea de una variable endógena retardada espacialmente, y el Robust LM-Lag al revés
- Lo importante a recordar respecto a los tests robustos es que estos sólo deben considerarse cuando la versión estándar (LM-Lag o LM-Error) son estadísticamente significativos
- Los tests robustos ayudan a determinar que tipo de dependencia espacial existe. Si las medidas robustas de lag y error son ambas significativas, la estructura de la autocorrelación espacial estará determinada por el test robusto con mayor valor


Comparación de modelos

La estrategia simple propuesta por Anselin (2005) y Florax et al (2003) es (*The bottom-up approach*):




Comparación de modelos

La estrategia de LeSage y Pace (2009) (*The top-down approach*):



Comparación de modelos

La estrategia de Elhorst (2010):



Comparación de modelos

Por tanto, Elhorst (2010) propone el siguiente procedimiento para determinar qué modelo es el candidato más probable para explicar los datos:

1. Estime el modelo por MCO y pruebe si el *spatial lag model* - SAR o el *spatial error model* - SEM es más apropiado para describir los datos. Para esto, se puede utilizar el LM-test propuesto por Anselin (1988) y el robust LM-test propuesto por Anselin et al. (1996)
2. Si el modelo MCO es rechazado en favor del *spatial lag model*, *spatial error model* o en favor de ambos modelos, entonces el modelo Durbin espacial debería ser estimado
3. Si estos modelos son estimados por ML, un LR test puede ser usado para probar las hipótesis:
 - $H_0: \theta=0 \rightarrow$ prueba si el modelo Durbin espacial se puede simplificar en el *spatial lag model*
 - $H_0: \theta+\rho\beta=0 \rightarrow$ prueba si el modelo Durbin espacial se puede simplificar en el *spatial error model*
 - Si $H_0: \theta=0$ y $H_0: \theta+\rho\beta=0$ son rechazadas $\rightarrow$ modelo Durbin espacial
 - Si $H_0: \theta=0$ no puede ser rechazada $\rightarrow$ *spatial lag model* (siempre que el (robust) LM-test diga lo mismo)
 - Si $H_0: \theta+\rho\beta=0$ no puede ser rechazada $\rightarrow$ *spatial error model* (siempre que el (robust) LM-test diga lo mismo)
 - Si el (robust) LM-test apunta a un modelo diferente que el LR test $\rightarrow$ modelo Durbin espacial
4. Si el modelo MCO es estimado y no rechaza en favor del *spatial lag model* y el *spatial error model*, el modelo MCO deberá ser re-estimado incluyendo $\textbf{WX}$ o una particular selección de estas (K) variables para probar $H_0: \theta=0$
 - Si la hipótesis no puede ser rechazada $\rightarrow$ modelo MCO
 - Si la hipótesis es rechazada $\rightarrow$ modelo Durbin espacial y se debe contrastar $H_0: \rho=0$
 - Si esta última hipótesis es rechazada $\rightarrow$ modelo Durbin espacial
 - Si esta última hipótesis es no rechazada $\rightarrow$ modelo SLX

Efectos directos e indirectos (o *spatial spillover effects*)

- Muchos estudios empíricos usan las estimaciones puntuales de una o más especificaciones de modelos de regresión espacial ρ , θ y/o λ para deducir conclusiones sobre la existencia de spillovers espaciales $\rightarrow$ LeSage y Pace (2009, p. 74) plantean y demuestran que esta práctica lleva a erróneas conclusiones
- Re-escribiendo el modelo *GNSM*:
$$\textbf{Y} = (\textbf{I} - \rho \textbf{W})^{-1} (\textbf{X} \boldsymbol{\beta} + \textbf{W} \textbf{X} \boldsymbol{\theta}) + \textbf{R}$$
 donde $\textbf{R}$ es un término que contiene el intercepto y el término de error, la matriz de derivadas parciales del valor esperado de $\textbf{Y}$ con respecto a la k -ésima variable explicatoria de $\textbf{X}$ es:

$$\left[\begin{array}{ccc} \frac{\partial E(\textbf{Y})}{\partial x_{1k}} & \dots & \frac{\partial E(\textbf{Y})}{\partial x_{Nk}} \\ \frac{\partial E(y_1)}{\partial x_{1k}} & \dots & \frac{\partial E(y_1)}{\partial x_{Nk}} \\ \vdots & \ddots & \vdots \\ \frac{\partial E(y_N)}{\partial x_{1k}} & \dots & \frac{\partial E(y_N)}{\partial x_{Nk}} \end{array} \right] = (\textbf{I} - \rho \textbf{W})^{-1} \left[\begin{array}{cccc} \beta_k & w_{12} \theta_k & \dots & w_{1N} \theta_k \\ w_{21} \theta_k & \beta_k & \dots & w_{2N} \theta_k \\ \vdots & \vdots & \ddots & \vdots \\ w_{N1} \theta_k & w_{N2} \theta_k & \dots & \beta_k \end{array} \right]$$

Efectos directos e indirectos (o *spatial spillover effects*)

Esta derivada parcial tiene tres importantes propiedades:

1. Si una variable explicatoria particular en una unidad espacial particular cambia, no sólo cambiará la variable dependiente en esa unidad espacial, sino también cambiará en otras unidades espaciales

- El primer cambio se llama **efecto directo**: cada elemento de la diagonal
- El segundo cambio se llama **efecto indirecto**: cada elemento por fuera de la diagonal

Los efectos indirectos no ocurren si $\rho=0$ y $\theta_k=0$, ya que los elementos por fuera de la diagonal serían cero

2. Los efectos directos e indirectos son diferentes para diferentes unidades espaciales en la muestra

- Los efectos directos son diferentes ya que los elementos de la diagonal de la matriz $(\mathbf{I} - \rho \mathbf{W})^{-1}$ son diferentes para cada unidad espacial, siempre que $\rho \neq 0$
- Los efectos indirectos son diferentes ya que los elementos de la diagonal de la matriz $(\mathbf{I} - \rho \mathbf{W})^{-1}$ y de la matriz $\mathbf{W}$ son diferentes entre unidades espaciales, siempre que $\rho \neq 0$ y/o $\theta_k \neq 0$

3. Los efectos indirectos que ocurren si $\theta_k \neq 0$ son conocidos como **efectos locales**, como opuesto al efecto indirecto que ocurre si $\rho \neq 0$ que son llamados **efectos globales**

Efectos directos e indirectos (o *spatial spillover effects*)

- Ya que los efectos directos e indirectos son diferentes para diferentes unidades espaciales, la presentación de estos efectos puede ser problemático $\rightarrow$ (N) unidades espaciales y (K) variables explicatorias, se obtiene (K) diferentes $(N \times N)$ matrices de efectos directos e indirectos
- LeSage y Pace (2009) proponen lo siguiente:
 - **Efectos directos**: promedio de los elementos de la diagonal de la matriz
 - **Efectos indirectos**: promedio de las filas o las columnas de los elementos por fuera de la diagonal
- **Promedio de las filas**: el impacto sobre un particular unidad espacial de la variable dependiente ante un cambio en todas las variables explicatorias en todas las unidades espaciales
- **Promedio de las columnas**: el impacto de cambiar la variable explicatoria en una unidad espacial sobre la variable dependiente de todas las unidades espaciales
- Sin embargo, numéricamente las dos magnitudes son iguales, por lo cual no importa por cual se opte
- **Interpretación del efecto indirecto**: el impacto de cambiar un particular elemento de una variable exógena sobre la variable dependiente de todas las otras unidades espaciales, lo cual corresponde al promedio del efecto columna

Efectos directos e indirectos (o *spatial spillover effects*)

Cuadro 1. Efectos directos e indirectos de diferentes modelos		
	Efecto directo	Efecto indirecto
MCO/SEM	β_k	0
SAR/SAC	Diagonal de $(\mathbf{I} - \rho \mathbf{W})^{-1} \beta_k$	<i>Off-diagonal</i> de $(\mathbf{I} - \rho \mathbf{W})^{-1} \beta_k$
SLX/SDM	β_k	θ_k
SDM/GNSM	Diagonal de $(\mathbf{I} - \rho \mathbf{W})^{-1} (\beta_k + \mathbf{W} \theta_k)$	<i>Off-diagonal</i> de $(\mathbf{I} - \rho \mathbf{W})^{-1} (\beta_k + \mathbf{W} \theta_k)$
Fuente: Halleck Vega y Elhorst (2015)		

Ejercicio aplicado en R: corte transversa

En este ejercicio aplicado se va analizar los determinantes de la tasa de vivienda propia para NYC a nivel de Census track. En los siguientes links se encuentran el shapefile y el código utilizado en R:

- [Shapefile](#)
- [Código en R](#)

Ejercicio aplicado en R: datos panel

En este ejercicio aplicado se va analizar los crímenes violentos en los estados de los Estados Unidos. En los siguientes links se encuentran los datos, el shapefile y el código utilizado en R:

- [Datos](#)
- [Shapefile](#)
- [Código en R](#)